IMPORTANT ❗ ❗ ❗ Please remember to destroy all the resources after each work session. You can recreate infrastructure by creating new PR and merging it to master.

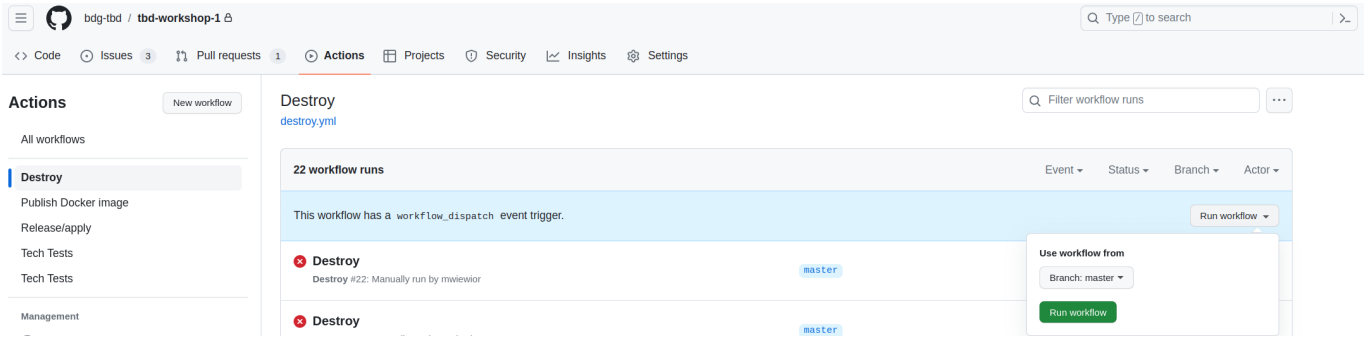

0. The goal of this phase is to create infrastructure, perform benchmarking/scalability tests of sample three-tier lakehouse solution and analyze the results using:

- TPC-DI benchmark
- dbt - data transformation tool
- GCP Composer - managed Apache Airflow
- GCP Dataproc - managed Apache Spark
- GCP Vertex AI Workbench - managed JupyterLab

Worth to read:

- https://docs.getdbt.com/docs/introduction
- https://airflow.apache.org/docs/apache-airflow/stable/index.html
- https://spark.apache.org/docs/latest/api/python/index.html
- https://medium.com/snowflake/loading-the-tpc-di-benchmark-dataset-into-snowflake-96011e2c26cf
- https://www.databricks.com/blog/2023/04/14/how-we-performed-etl-one-billion-records-under-1-delta-live-tables.html

2. Authors:

   Team 13

   Link to forked repo

3. Sync your repo with https://github.com/bdg-tbd/tbd-workshop-1.

4. Provision your infrastructure.

   ```
   a) setup Vertex AI Workbench `pyspark` kernel as described in point [8]
   (https://github.com/bdg-tbd/tbd-workshop-1/tree/v1.0.32#project-setup)

   b) upload [tpc-di-setup.ipynb](https://github.com/bdg-tbd/tbd-workshop-1/blob/v1.0.36/notebooks/tpc-di-setup.ipynb) to
   ```

   the running instance of your Vertex AI Workbench

5. In `tpc-di-setup.ipynb` modify cell under section ***Clone tbd-tpc-di repo***:

a)first, fork https://github.com/mwiewior/tbd-tpc-di.git to your github organization.

b)create new branch (e.g. 'notebook') in your fork of tbd-tpc-di and modify profiles.yaml by commenting following lines:

```
     #"spark.driver.port": "30000"
     #"spark.blockManager.port": "30001"
     #"spark.driver.host": "10.11.0.5"  #FIXME: Result of the command
(kubectl get nodes -o json |  jq -r '.items[0].status.addresses[0].address')
     #"spark.driver.bindAddress": "0.0.0.0"
```

This lines are required to run dbt on airflow but have to be commented while running dbt in notebook.

c)update git clone command to point to ***your fork***.

6. Access Vertex AI Workbench and run cell by cell notebook `tpc-di-setup.ipynb`.

```
a) in the first cell of the notebook replace: `%env DATA_BUCKET=tbd-2023z-
9910-data` with your data bucket.

b) in the cell:
`%%bash
```

mkdir -p git && cd git git clone https://github.com/mwiewior/tbd-tpc-di.git cd tbd-tpc-di git pull ` replace repo with your fork. Next checkout to 'notebook' branch.

```
c) after running first cells your fork of `tbd-tpc-di` repository will be
cloned into Vertex AI enviroment (see git folder).

d) take a look on `git/tbd-tpc-di/profiles.yaml`. This file includes Spark
parameters that can be changed if you need to increase the number of
executors and
```

```
server_side_parameters:
    "spark.driver.memory": "2g"
    "spark.executor.memory": "4g"
    "spark.executor.instances": "2"
    "spark.hadoop.hive.metastore.warehouse.dir": "hdfs:///user/hive/warehouse/"
```

7. Explore files created by generator and describe them, including format, content, total size.

Wygenerowany zestaw danych to TPC-DI (Transaction Processing Performance Council - Data Integration). TPC-DI jest standardem do testowania wydajności baz danych przy użyciu generowanych danych.

Plik *Batch1_audit.csv* zawiera dwa wiersze informujące o przedziale czasowym, z którego pochodzą dane - dane z przeprowadzanego audytu finansowego. Pierwszy wiersz przedstawia datę początkową (rok 1950), a drugi – datę końcową (rok 2017). Dane te obejmują zatem rozległy okres historyczny. Analogiczne informacje znajdują się w plikach *Batch2_audit.csv* oraz *Batch3_audit.csv*, lecz dotyczą one bardziej aktualnych i krótszych przedziałów czasowych: *Batch2_audit.csv* zawiera dane z dnia 2017-07-08 (odpowiadające dniowi poprzedniemu), *Batch3_audit.csv* odnosi się do dnia 2017-07-09 (reprezentując dzień bieżący).

W folderach *Batch1, Batch2* oraz *Batch3* znajdują się dane dotyczą różnych aspektów działalności audytowanych przedsiębiorstw, obejmujące takie obszary jak transakcje gotówkowe (Cash transaction), zarządzanie klientami (Customer management) czy codzienny rynek (Daily market).

Do każdej dziedziny danych wygenerowane zostały dwa pliki - jeden w formacie csv, drugi w txt (przykładowo *TradeHistory_audit.csv* oraz *TradeHistory.txt*). Plik CSV zawiera podsumowanie i agregację danych, przedstawiając różne atrybuty związane z daną dziedziną. Znajdują się tam takie informacje jak liczba rekordów, operacji czy zdarzeń w określonym okresie czasu. Może zawierać również dane o stanie różnych elementów, takich jak liczba utworzonych kont, zamkniętych transakcji, zaktualizowanych informacji, itp. Plik TXT zawiera już szczegółowe dane o każdym rejestrowanym zdarzeniu, często w formie zapisów transakcji lub innych jednostkowych zdarzeń. Zawiera informacje takie jak daty, wartości operacji, identyfikatory, a także inne szczegóły związane z każdym zdarzeniem. W przeciwieństwie do pliku CSV, plik tekstowy może być używany do bardziej zaawansowanej analizy, np. w przypadku potrzeby prześledzenia poszczególnych operacji w danej dziedzinie.

Podsumowanie liczby rekordów:

```
jupyter@0115ef734e8f:/tmp/tpc-di$ cat digen_report.txt
TPC-DI Data Generation Report
=============================

Start Time: 2025-01-06T15:42:51+0000
End Time: 2025-01-06T15:44:42+0000
DIGen Version: 1.1.0
Scale Factor: 10
AuditTotalRecordsSummaryWriter - TotalRecords for Batch1: 15980433
AuditTotalRecordsSummaryWriter - TotalRecords for Batch2: 67451
AuditTotalRecordsSummaryWriter - TotalRecords for Batch3: 67381
AuditTotalRecordsSummaryWriter - TotalRecords all Batches: 16115265 151524.77 records/second

Command options used: -sf 10 -o /tmp/tpc-di
PDGF Version: PDGF v2.5_#1343_b4177
Java version: Amazon.com Inc. 1.8.0_392
jupyter@0115ef734e8f:/tmp/tpc-di$
```

Łączny rozmiar danych:

```
jupyter@0115ef734e8f:/tmp$ du -sh tpc-di/
962M    tpc-di/
jupyter@0115ef734e8f:/tmp$
```

8. Analyze tpcdi.py. What happened in the loading stage?

W kodzie tpcdi.py, który uruchamiany był w loading stage, zdefiniowana jest funkcja *upload_files*, która przesyła pliki do Google Cloud Storage lub innej lokalizacji wskazanej przez stage*path. Funkcja ta przeszukuje katalog output_directory w poszukiwaniu plików pasujących do wzorca, a następnie w zależności od typu pliku ustawia odpowiedni delimiter (np. przecinek dla CSV). Następnie pliki są przesyłane do chmury, a ich nazwa jest używana jako nazwa bloba w GCS. Jest ona wywoływana przez funkcję _load_csv*.

Kolejnym krokiem jest funkcja *load_csv*, która odpowiedzialna jest za załadowanie plików CSV z GCS do DataFrame w Spark. Na początku ustalana jest ścieżka do wgranego pliku, a potem wywoływana jest funkcja *upload_files*, która załadowuje pliki do GCS. Następnie dane z GCS są wczytywane przy użyciu Spark, z uwzględnieniem podanego schematu, który opisuje strukturę danych w pliku. Po załadowaniu danych, wynikowy DataFrame jest przekazywany do funkcji *save_df*.

Funkcja *save_df* sprawdza, czy zmienna show jest ustawiona na True. Jeśli tak, dane w DataFrame są po prostu wyświetlane na ekranie za pomocą df.show(). Jeśli show jest ustawione na False, dane są zapisywane do systemu w formacie parquet, a dodatkowo tworzona jest tabela o nazwie określonej przez table_name. Tabela jest zapisywana w trybie nadpisywania, co oznacza, że jeżeli tabela o tej samej nazwie już istnieje, zostanie zastąpiona.

Pliki zostały wgrane do naszego bucketa w GCS:

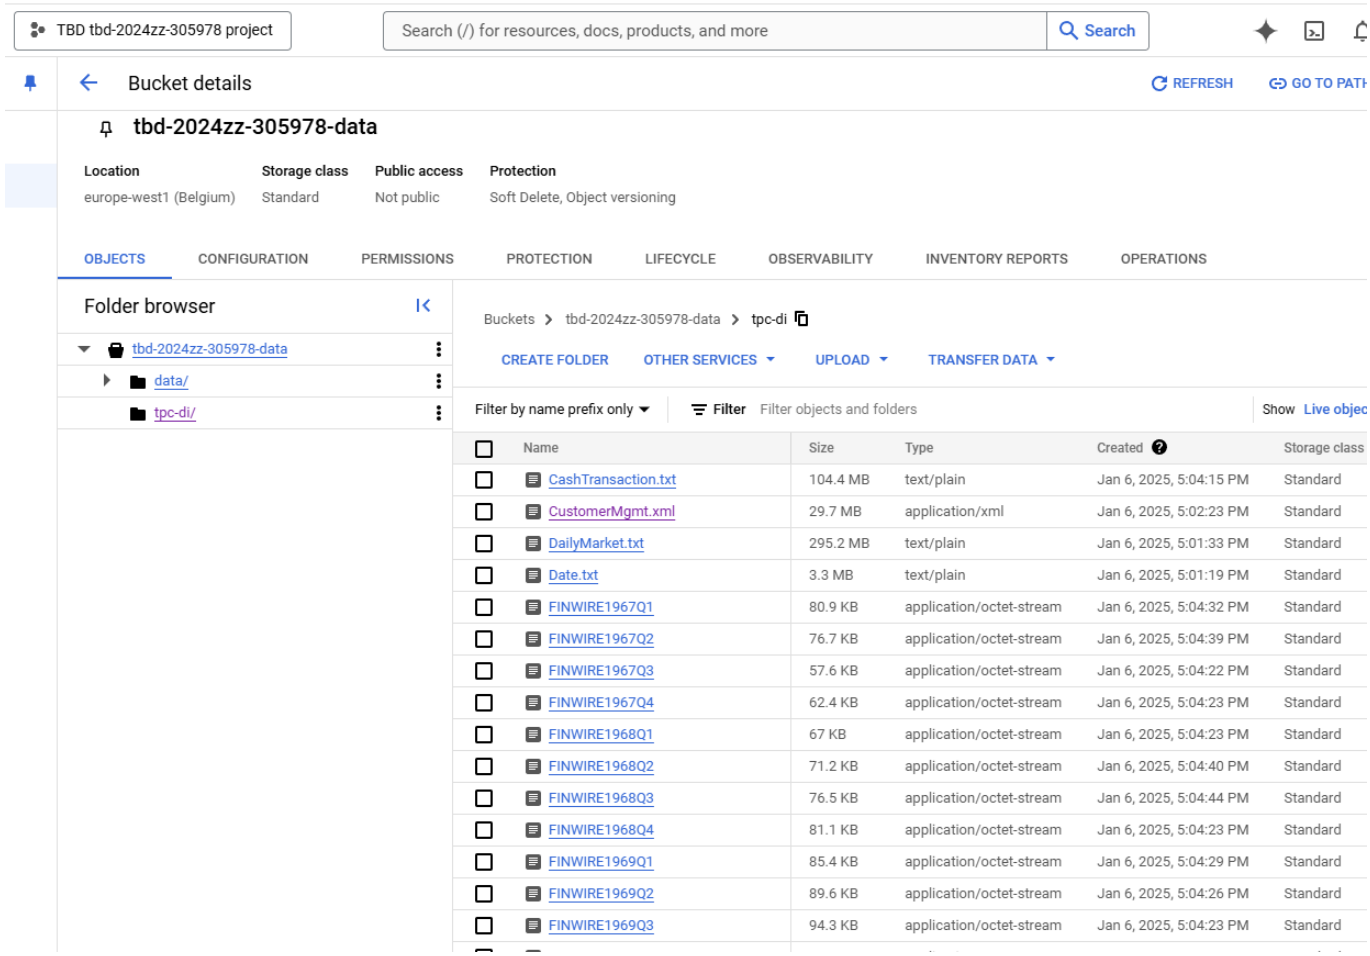

9. Using SparkSQL answer: how many table were created in each layer?

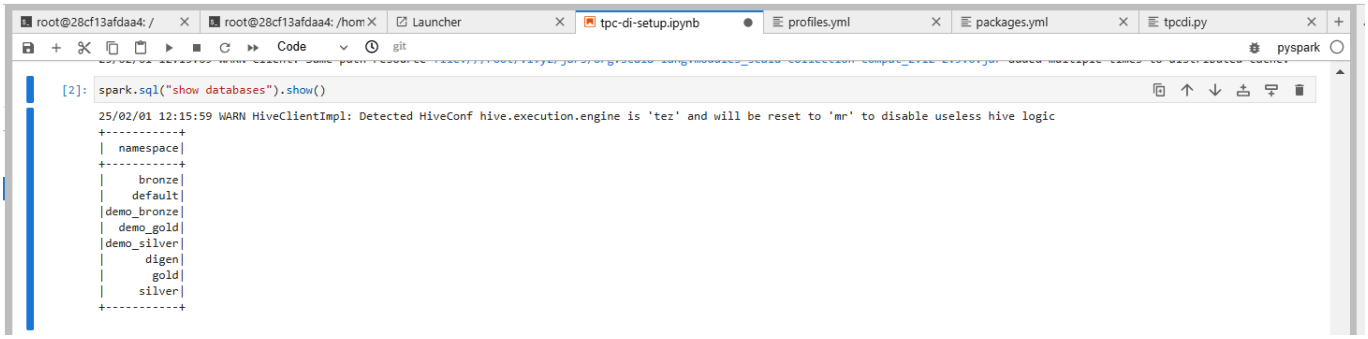

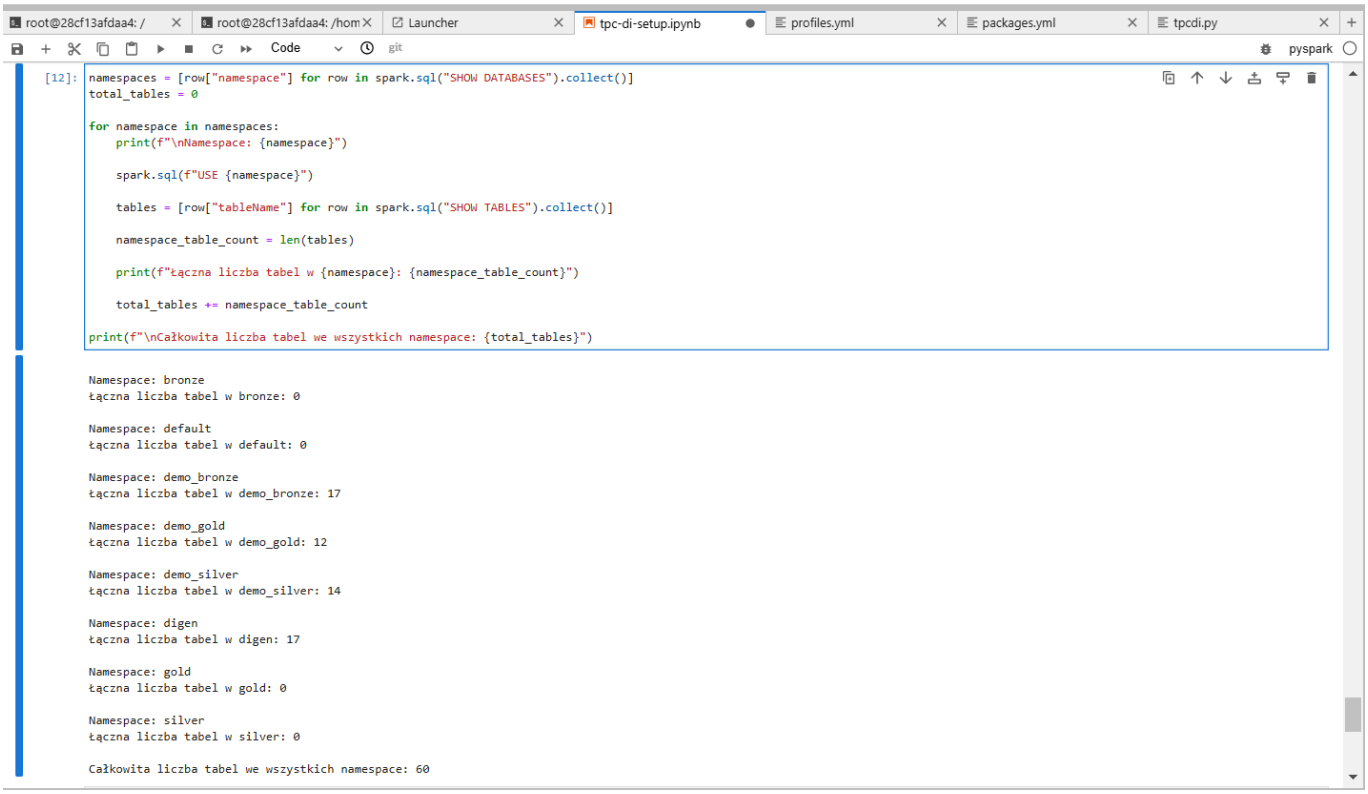

10. Add some 3 more dbt tests and explain what you are testing. ***Add new tests to your repository.***

    Link do folderu z testami: test

Test 1. Sprawdza, czy wartości w kolumnie `executed_by` nie są NULL ani puste.

```
SELECT
    sk_trade_id,
    executed_by
FROM {{ ref('fact_trade') }}
WHERE executed_by IS NULL OR executed_by = ''
```

Test 2. Sprawdza, czy wartości w kolumnie `sk_trade_id` nie są NULL.

```
SELECT
    sk_trade_id
FROM {{ ref('fact_trade') }}
WHERE sk_trade_id IS NULL
```

Test 3. Sprawdza, czy suma wartości w kolumnie `amount` dla każdego `order_id` nie jest ujemna.

```
    select
        order_id,
        sum(amount) as total_amount
    from {{ ref('fct_payments') }}
    group by 1
    having total_amount < 0
```

Test 4. Sprawdza, czy wartości w kolumnie `trade_price` dla każdego `sk_trade_id` nie są ujemne.

```
      SELECT
       sk_trade_id,
       trade_price
   FROM {{ ref('fact_trade') }}
   WHERE trade_price < 0
```

11. In main.tf update

```
dbt_git_repo            = "https://github.com/mwiewior/tbd-tpc-di.git"
dbt_git_repo_branch     = "main"
```

so dbt_git_repo points to your fork of tbd-tpc-di.

Zmieniliśmy wartość parametru żeby wskazywała na naszego forka:

```
dbt_git_repo            = "https://github.com/spacerunner00/tbd-tpc-di.git""
dbt_git_repo_branch     = "main"
```

12. Redeploy infrastructure and check if the DAG finished with no errors:

Composer ← Environment details OPEN AIRFLOW UI OPEN DAGS FOLDER SAVE SNAPSHOT LOAD SNAPSHOT REFRESH DELETE LEARN

demo-lab This environment is running

MONITORING LOGS DAGS ENVIRONMENT CONFIGURATION AIRFLOW CONFIGURATION OVERRIDES ENVIRONMENT VARIABLES LABELS PYPI PACKAGES

Filter Filter DAGs 1 hour 6 hours 12 hours 1 day 2 days 4 days 7 days 14 days 30 days

DAG id	State	Description	Schedule interval	Last completed run	Active runs	Successful runs (1h)	Failed runs (1h)
airflow_monitoring	Active	liveness monitoring dag	*/10 * * * *	5 minutes ago	0	6	0
composer_sample_dbt_task	Active		1 day	44 minutes ago	0	1	0
dataproc_job	Active		1 day	44 minutes ago	0	1	0

SEVERITY	TIMESTAMP	SUMMARY
	2025-02-01 13:50:23.121 UTC	[base] WARNING: Illegal reflective access by org.apache.hadoop.shaded.org.xbill.DNS.ResolverConfig (file:/usr/local/lib/python3.10/site-packages/pyspark/jars/hadoop-client-run…
	2025-02-01 13:50:23.121 UTC	[base] WARNING: Please consider reporting this to the maintainers of org.apache.hadoop.shaded.org.xbill.DNS.ResolverConfig
	2025-02-01 13:50:23.121 UTC	[base] WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
	2025-02-01 13:50:23.145 UTC	[base] WARNING: All illegal access operations will be denied in a future release
	2025-02-01 13:50:27.145 UTC	[base] 25/02/01 13:50:23 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
	2025-02-01 13:50:27.325 UTC	[base] 25/02/01 13:50:27 WARN DomainSocketFactory: The short-circuit local reads feature cannot be used because libhadoop cannot be loaded.
	2025-02-01 13:51:30.588 UTC	[base] 25/02/01 13:50:27 WARN Client: Neither spark.yarn.jars nor spark.yarn.archive is set, falling back to uploading libraries under SPARK_HOME.
	2025-02-01 13:51:30.589 UTC	[base] [0m13:51:30 Connection test: [[32mOK connection ok [0m] 2025-02-01T13:51:30.578718343Z
	2025-02-01 13:51:32.596 UTC	[base] [0m13:51:30 [32mAll checks passed! [0m
	2025-02-01 13:51:32.928 UTC	Pod dbt-task-go7hclsl has phase Running
	2025-02-01 13:51:35.167 UTC	Deleting pod: dbt-task-go7hclsl
	2025-02-01 13:51:35.505 UTC	Marking task as SUCCESS. dag_id=composer_sample_dbt_task, task_id=dbt-task, execution_date=20250131T134745, start_date=20250201T134923, end_date=20250201T135135
	2025-02-01 13:51:36.304 UTC	Task exited with return code 0
	2025-02-01 13:51:36.464 UTC	0 downstream tasks scheduled from follow-on schedule check

Composer ← Environment details OPEN AIRFLOW UI OPEN DAGS FOLDER SAVE SNAPSHOT LOAD SNAPSHOT REFRESH DELETE LEARN

demo-lab This environment is running

MONITORING LOGS DAGS ENVIRONMENT CONFIGURATION AIRFLOW CONFIGURATION OVERRIDES ENVIRONMENT VARIABLES LABELS PYPI PACKAGES

Filter Filter DAGs 1 hour 6 hours 12 hours 1 day 2 days 4 days 7 days 14 days 30 days

DAG id	State	Description	Schedule interval	Last completed run	Active runs	Successful runs (1h)	Failed runs (1h)
airflow_monitoring	Active	liveness monitoring dag	*/10 * * * *	5 minutes ago	0	6	0
composer_sample_dbt_task	Active		1 day	44 minutes ago	0	1	0
dataproc_job	Active		1 day	44 minutes ago	0	1	0

Airflow DAGs Datasets Browse Admin Docs Composer 14:36 UTC A-

demo-lab

All 3 Active 3 Paused 0 Filter DAGs by tag Search DAGs Auto-refresh

DAG	Owner	Runs	Schedule	Last Run	Next Run	Recent Tasks	Actions	Links
airflow_monitoring	airflow	6	*/10 * * * *	2025-02-01, 14:20:00	2025-02-01, 14:20:00	1		
composer_sample_dbt_task	airflow	1	1 day, 0:00:00	2025-01-31, 13:47:45	2025-02-01, 13:47:45	1		
dataproc_job	airflow	1	1 day, 0:00:00	2025-01-31, 00:00:00	2025-02-01, 00:00:00	1		

« ‹ 1 › »

Showing 1-3 of 3 DAGs

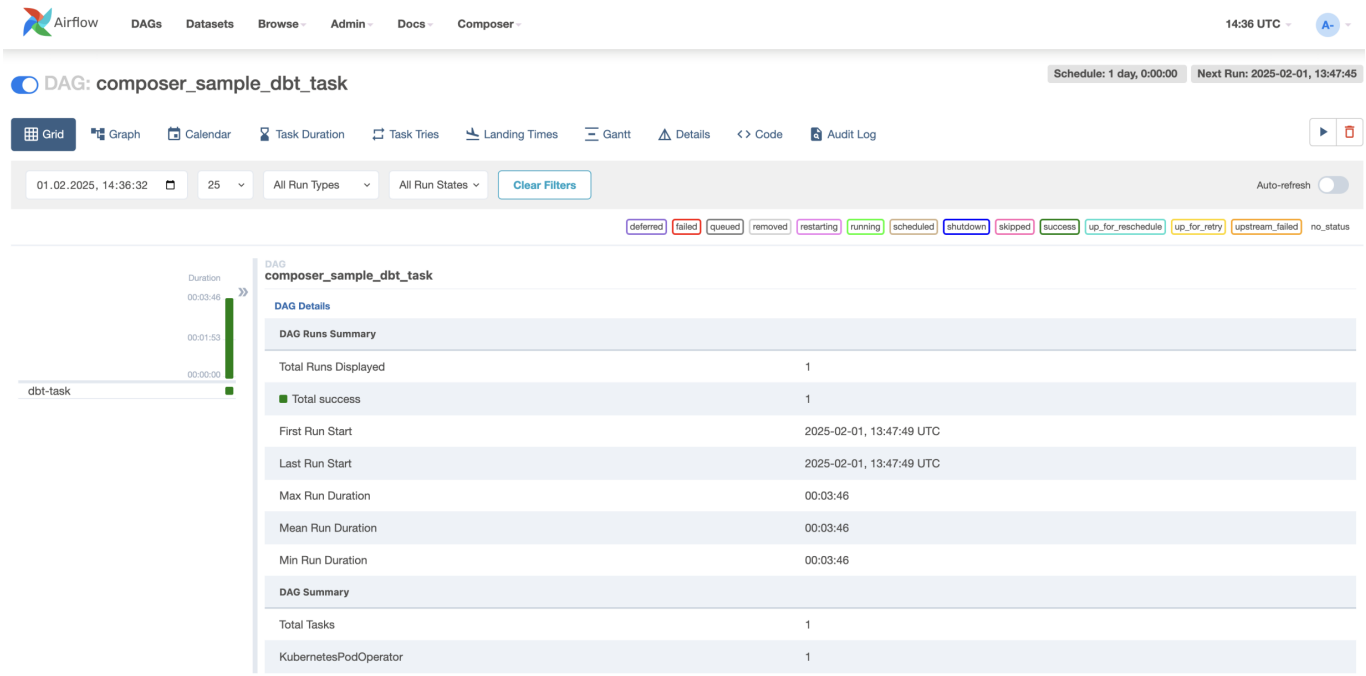
Airflow
DAGs
Datasets
Browse
Admin
Docs
Composer
14:36 UTC
DAG: composer_sample_dbt_task
Schedule: 1 day, 0:00:00
Next Run: 2025-02-01, 13:47:45
Grid
Graph
Calendar
Task Duration
Task Tries
Landing Times
Gantt
Details
Code
Audit Log
01.02.2025, 14:36:32
25
All Run Types
All Run States
Clear Filters
Auto-refresh
deferred
failed
queued
removed
restarting
running
scheduled
shutdown
skipped
success
up_for_reschedule
up_for_retry
upstream_failed
no_status
Duration
00:03:46
00:01:53
00:00:00
dbt-task
DAG
composer_sample_dbt_task
DAG Details
DAG Runs Summary
Total Runs Displayed 1
Total success 1
First Run Start 2025-02-01, 13:47:49 UTC
Last Run Start 2025-02-01, 13:47:49 UTC
Max Run Duration 00:03:46
Mean Run Duration 00:03:46
Min Run Duration 00:03:46
DAG Summary
Total Tasks 1
KubernetesPodOperator 1

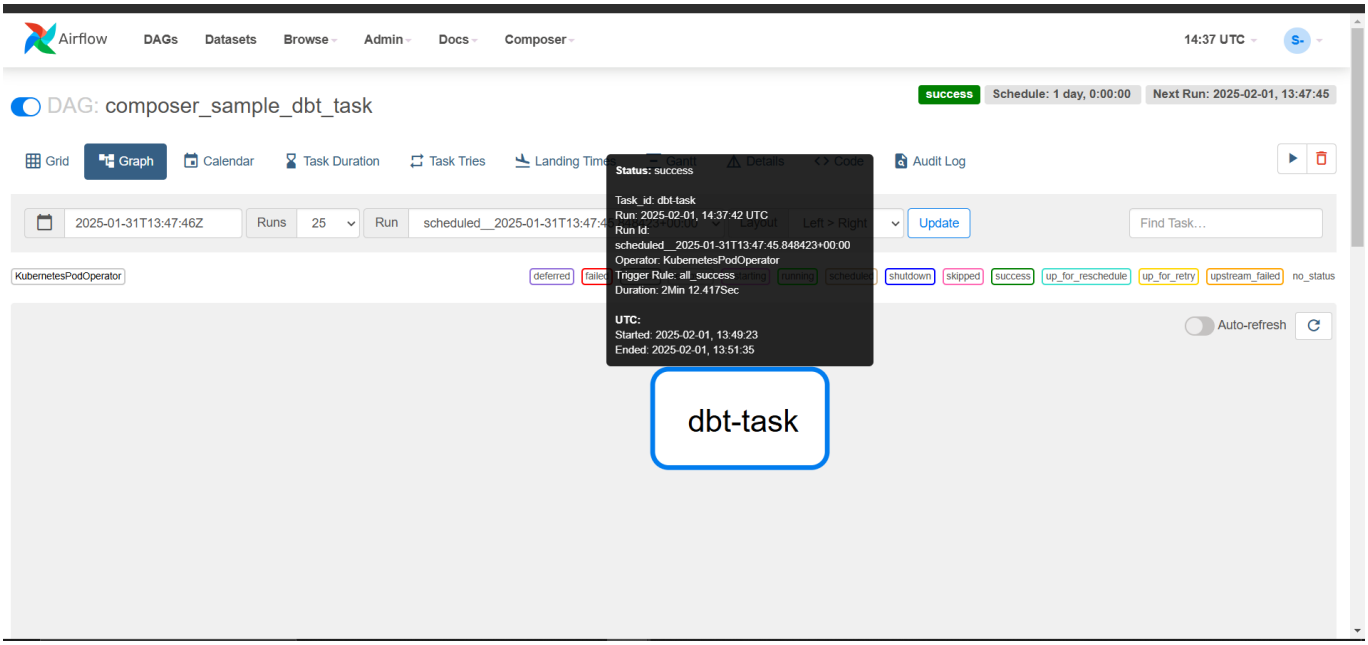
Airflow
DAGs
Datasets
Browse
Admin
Docs
Composer
14:37 UTC
DAG: composer_sample_dbt_task
success
Schedule: 1 day, 0:00:00
Next Run: 2025-02-01, 13:47:45
Grid
Graph
Calendar
Task Duration
Task Tries
Audit Log
2025-01-31T13:47:46Z
Runs
25
Run
Update
Find Task...
KubernetesPodOperator
Auto-refresh
Status: success
Task_id: dbt-task
Run: 2025-02-01, 14:37:42 UTC
Run Id:
scheduled__2025-01-31T13:47:45.848423+00:00
Operator: KubernetesPodOperator
Trigger Rule: all_success
Duration: 2Min 12.417Sec
UTC:
Started: 2025-02-01, 13:49:23
Ended: 2025-02-01, 13:51:35
dbt-task